报告正文（2026版）

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。申请书正文原则上不超过30页，鼓励简洁表达。**请勿删除或改动下述提纲标题及括号中的文字。**

（一）立项依据

（为什么要开展此项研究，研究的科学技术价值如何）

1.1 研究意义与国家战略需求

当前，服务机器人虽已具备基础的场景导航与物体操作能力，却普遍缺乏与人类情感韵律相协调的非语言行为（Non-verbal Behavior）表达能力。心理学与人机交互领域的研究表明，在面对面交流中，超过60%的信息传递依赖于面部表情、手势节律与躯干姿态等副语言信号 [1]。这一非语言表达能力的缺口，导致当前的人机交互过程充满机械感与割裂感，已成为制约具身智能在适老化陪护、医疗康复等非结构化社会民生场景中真正落地的关键瓶颈。

在国家战略层面，突破上述交互认知瓶颈具有迫切的现实需求。党的二十届三中全会通过的《中共中央关于进一步全面深化改革推进中国式现代化的决定》明确提出，要加强未来产业前瞻布局。工信部《人形机器人创新发展指导意见》[2] 与工信部等七部门于2024年联合发布的《关于推动未来产业创新发展的实施意见》中，明确将“突破机器人大脑认知与小脑控制协同瓶颈，构建高可靠、高交互的人机共融系统”列为核心攻关任务 [3]。2024年《政府工作报告》首次提出“人工智能+”行动 [4]，进一步指向生成式大模型技术从数字内容生成向物理实体赋能的跨越。从“十五五”规划 [5] 到《人形机器人与具身智能标准体系（2026版）》 [6]，政策层面的对具身智能和机器人的支持力度持续加码。这一系列宏观战略部署直接指向了本项目所针对的核心难题：如何使实体机器人超越冰冷的指令执行，真正理解复杂社交语境，并以高表现力、拟人化的肢体语言作出自然反馈。

在民生需求层面，面对我国日益加剧的人口老龄化趋势，国务院办公厅《关于发展银发经济增进老年人福祉的意见》[7] 指出，居家养老与机构陪护场景中，老年群体对智能装备的需求已从单一的物理辅助延伸至深层的情感慰藉。现有服务机器人在移动导航与机械抓取方面已初步成熟，但在多模态情感表达上仍存在显著空白。这种“有执行力、无共情力”的现状，不仅无法消弭人机交互中的“恐怖谷效应”，反而易引发使用者的认知负荷与排斥心理 [8]，从根本上阻断

了老年群体与机器人建立长期情感信任的可能。

在理论指导与范式演进层面，北京航空航天大学赵沁平院士团队近期提出的“共身智能（Cobodied/Symbodied AI）”前沿理念 [9] 为突破上述交互瓶颈提供了系统性的理论框架。该理论指出，下一代智能体应从以物理环境适应为核心的“具身”，演进为以人机认知对齐为目标的“共身”；强调通过跨智能体的语义对齐与物理协同，实现真正意义上的人机共融。本项目立足这一前沿视角，针对具备高移动稳定性的履带式上半身人形机器人构型，深入探究面向共身智能的高表现力社交动作感知与生成机制。本项目旨在从科学机理上阐明：**跨模态情感语义如何有效跨越虚实鸿沟，驱动受限于动力学边界的刚性机器人实体，呈现出柔性、共情且符合人类社会交互规范的高表现力行为。**

1.2 国内外研究现状与发展动态分析

围绕具身智能交互与高保真动作生成，国内外学者近年来开展了大量前沿探索。然而，面向真实物理实体的高表现力社交动作生成，仍横跨机器人学与计算机图形学，面临诸多学科交叉维度的理论空白。

1. 具身控制与 VLA 大模型：物理操作精细，但社交语义贫瘠。在具身机器人的端到端控制领域，“视觉-语言-动作（VLA）”范式已展现出强大的泛化潜力。从早期的 RT-2 [10]，到近期开源的 Octo [11] 与 OpenVLA [12]，研究者通过联合训练视觉语言模型与机器人轨迹，实现了对未见物体与指令的零样本泛化。更进一步，结合扩散策略（Diffusion Policy） [13] 与流匹配（Flow Matching，如 $\pi_{0.5}$ 等工作 [14]）的最新物理智能架构，显著提升了多步任务序列生成的连续性与多模态对齐精度。

然而，究其数据来源与优化目标，上述 VLA 工作绝大多数依赖于遥操作（Teleoperation）采集的大规模数据集（如 Open X-Embodiment [15]）。在此类采集中，操作员的全部注意力集中于末端执行器（End-effector）的位姿精度，导致数据集中极度缺乏面部表情、头部注视与自然的肢体伴随动作。换言之，现有动作标注以“物理任务完成率”为单一优化目标，缺乏对情感意图的深层刻画，更未建立头-面-手-躯干的多部位协同机制。当面临“对低落情绪做出安抚反馈”等复合社交指令时，现有框架缺乏对副语言信息的表征能力，暴露出当前具身控制基座模型在情感感知与非语言行为维度的系统性贫瘠。

2. 语音驱动的数字人生成：情感表现力丰富，但缺乏物理真实性。与之形成鲜明对比的是，在计算机图形学与虚拟数字人领域，由语音与文本驱动的高表现力动作生成技术已日趋成熟。借助 SMPL-X [16] 等参数化模型的统一表达，学术界已

能从海量单目互联网视频中提取高质量的交互数据。从早期的规则与自回归生成 [17]，到近年来基于扩散模型的生成算法（如 DiffSHEG [18]、MODA [19] 与 EMAGE [20]），实现了从语音音频到面部表情、手势甚至精细手指动作的高保真协同生成，在数字空间中达到了以假乱真的表现力。

尽管在视觉感知层面表现优异，但此类算法生成于无物理约束的纯运动学空间。其生成的动作流形往往存在关节角速度超限、不可实现的质心加速度以及严重的自碰撞问题。当这些基于纯几何生成的动作序列通过传统逆运动学（IK）映射至真实机器人时，极易因忽略电机峰值力矩与底盘动力学平衡，导致硬件过载、动作严重失真或触发急停保护 [21]。

3. 虚实迁移与重定向：追求动力学稳定，却造成表现力折损。为跨越上述“虚实鸿沟”，学术界开始探索基于强化学习（RL）的物理级虚实迁移（Sim-to-Real）框架。依托 NVIDIA Isaac Lab [22] 等高保真仿真环境进行物理智能训练 [23]，OmniH2O [24] 与 PHC [25] 等工作成功实现了利用人体动捕数据驱动人形机器人完成全身模仿。同时，Mobile ALOHA [26] 和 HumanPlus [27] 也证明了从人类运动视频学习全身操作策略的可行性。

然而，现有 RL 追踪框架多侧重于双足行走（Locomotion），基础操作平衡，或者末端抓取，其奖励函数通常对高动态的关节加速度与质心偏移施加严厉的惩罚项。这种保守的控制策略在面向“高动态情感社交动作”（如激动地挥手、前倾大笑）时，会强制将大幅度的柔性动作“抑制”为小幅度的僵硬动作，以换取底盘的绝对稳定。这种缺乏底盘协同抗扰动设计的重定向机制，导致源数据中丰富的情感语义与节律特征在跨平台映射中被系统性折损。

综上所述，现有研究在面向**“物理可行的高表现力社交动作生成”**这一交叉领域存在明显断层：具身智能 VLA 模型缺乏社交共情数据与属性建模；图形学生成方法缺乏物理动力学闭环约束；而现有的物理重定向技术又以牺牲情感表现力为代价换取稳定性。此外，在生成机制底层，离散的意图理解模型与连续的物理动作流形之间，尚未建立起严格的时空对齐理论。本项目正是针对这一交叉空白，提出面向共身智能的社会化多模态语言动作生成架构（Social-MLA），系统建立从感知解耦、物理映射到协同生成的完整科学研究框架。

1.3 拟解决关键科学问题

基于上述领域的学科瓶颈与本项目确立的共身智能感知与生成（Social-MLA）技术路线，拟在多模态感知解析、非线性异构映射与跨模态协同生成三个层面，解决以下递进的关键科学问题：

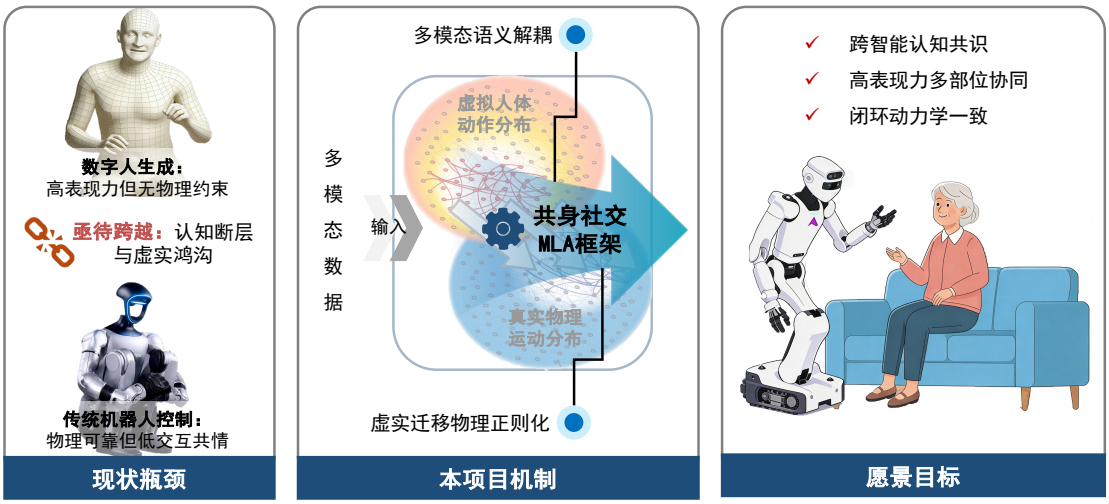

图 1. 项目总体研究思路与科学逻辑示意图。针对当前具身智能领域“懂物理操作但缺社交共情”的痛点，以及图形学数字人生成面临的“虚实鸿沟”，本项目提出面向人机共融的高表现力共身智能感知与生成机制（Social-MLA）。通过在特征空间对齐虚拟动作分布与真实物理约束，建立异构实体的认知-动作映射与物理级虚实迁移，赋予履带式人形机器人高表现力的社会化交互能力，实现人机在物理实体与认知语义层面的双重共融。

（1）复杂交互语境下多维非语言行为特征的时空同步解析与解耦机理

在自然的人机或人人对话场景中，面部微表情、视线焦点与肢体手势不仅存在高度的时序耦合，且在视觉捕获时常伴随严重的自遮挡与互遮挡。现有基于参数化人体模型的单向估计方法由于缺乏部位间的联合先验，难以剥离出多部位协同的深层意图规律。本项目的核心科学问题在于：在基于分析-合成（Analysis-by-Synthesis）的学习范式下，如何突破独立特征提取的局限，建立“表情-视线-动作”多维特征在复杂动态条件下的时空同步解析模型？进一步探明各类特征在情感表达中的权重分配与耦合规律，从而为下游生成任务提供兼具物理真实性与高判别性的感知先验。

（2）受限物理实体约束下的非线性拓扑映射与动力学边界补偿机制

将高达 145 个自由度的柔性人体动作重定向至低自由度的刚性履带式人形机器人时，拓扑结构的异构性与执行器的动力学极限（如关节力矩峰值、底盘倾覆力矩）会导致传统的一对一运动学映射严重失效，进而造成动作情感语义的结构性折损。本项目的核心科学问题在于：如何打破传统静态逆运动学解算的理论局限，将高保真物理仿真引擎的碰撞与动力学反馈作为隐式正则项引入映射优化的闭环？在此基础上，探究如何构建在约束流形上的非线性映射理论，实现“社交语义关键帧保真度”与“机器人动力学可行域”的联合最优解。

（3）离散语义 Token 驱动下的连续具身动作流形跨模态演化机理

高表现力交互动作的生成需要同时满足高层情感逻辑的离散结构性与底层关节物理控制的连续平滑性。现有的自回归大模型擅长处理离散Token序列，而流匹配（Flow Matching）等模型擅长构建连续的动作分布流形，两者在模态表征上存在深层鸿沟。本项目的核心科学问题在于：在融合大语言模型与常微分方程（ODE）求解的混合网络架构下，如何建立离散的多模态交互Token序列对ODE连续演化轨迹的有效引导与调制机制？进而揭示跨模态表征在解码过程中的对齐规律，使得最终生成的机器人在物理空间内的动作轨迹既符合语义空间的离散指令意图，又严格收敛于安全平滑的动力学边界内。

参考文献

[1] Mehrabian A. Silent Messages[M]. Belmont, CA : Wadsworth, 1971.

[2] 中华人民共和国工业和信息化部. 关于印发《人形机器人创新发展指导意见》的通知[Z]. 2023.

[3] 中华人民共和国工业和信息化部等七部门. 关于推动未来产业创新发展的实施意见[Z]. 2024.

[4] 中华人民共和国国务院. 2024年政府工作报告[Z]. 2024.

[5] 中共中央. 中共中央关于制定国民经济和社会发展第十五个五年规划的建议[Z]. 2025.

[6] 人形机器人与具身智能标准化年会. 人形机器人与具身智能标准体系（2026版）[Z]. 2026.

[7] 中华人民共和国国务院办公厅. 关于发展银发经济增进老年人福祉的意见[Z]. 2024.

[8] 乔红, 钟婉怡, 陈俊杰, 等. 类脑智能机器人: 理论、方法与应用[J]. 机器智能研究 (Machine Intelligence Research), 19(5), 2022.

[9] Lu F, Zhao Q. Towards cobodied/symbodied AI: Concept and eight scientific and technical problems[J/OL]. SCIENTIA SINICA Informationis, 55 : 444 – 448, 2025. http://dx.doi.org/10.1360/SSI-2024-0219.

[10] Brohan A, Brown N, Carbajal J, Chebotar Y, others. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[C] // Conference on Robot Learning (CoRL). 2023.

[11] Ghosh D, Walke H, Pertsch K, Black K, Mees O, Dasari S, Hejna J, Kreiman T, Xu C, Luo J, others. Octo: An Open-Source Generalist Robot Policy[C] // Robotics: Science and Systems (RSS). 2024.

[12] Kim M J, Pertsch K, Karamcheti S, Xiao T, Balakrishna A, Nair S, Rafailov R, Foster E, Sanketi P, Vuong Q, others. OpenVLA: An Open-Source Vision-Language-Action Model[C] // Conference on Robot Learning (CoRL). 2024.

[13] Chi C, Xu Z, Feng S, Cousineau E, Du Y, Burchfiel B, Tedrake R, Song S. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[C] // Robotics: Science and Systems (RSS). 2023.

[14] Intelligence P, Black K, Brown N, Darpinian J, Dhabalia K, Driess D, Esmail A, Equi M, Finn C, Fusai N, Galliker M Y, Ghosh D, Groom L, Hausman K, Ichter B, Jakubczak S, Jones T, Ke L, LeBlanc D, Levine S, Li-Bell A, Mothukuri M, Nair S, Pertsch K, Ren A Z, Shi L X, Smith L, Springenberg J T, Stachowicz K, Tanner J, Vuong Q, Walke H R, Walling A, Wang H, Yu L, Zhilinsky U. π0.5: a Vision-Language-Action Model with Open-World Generalization[J/OL]. ArXiv, abs/2504.16054, 2025. https://api.semanticscholar.org/CorpusID:277993634.

[15] Padalkar A, Pooley A, Jain A, others. Open X-Embodiment: Robotic Learning Datasets and

RT-X Models[C] // IEEE International Conference on Robotics and Automation (ICRA). 2024.
[16] Pavlakos G, Choutas V, Ghorbani N, Bolkart T, Osman A A A, Tzionas D, Black M J. Expressive Body Capture: 3D Hands, Face, and Body from a Single Image[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019.
[17] Ginosar S, Bar A, Kohavi G, Creers C, Malik J. Learning Individual Styles of Conversational Gesture[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019.
[18] Chen J, Liu Y, Wang J, Zeng A, Li Y, Chen Q. DiffSHEG: A Diffusion-Based Approach for Real-Time Speech-Driven Holistic 3D Expression and Gesture Generation[J/OL]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) : 7352 – 7361, 2024. https://api.semanticscholar.org/CorpusID:266902675.
[19] Liu Y, Lin L, Yu F, Zhou C, Li Y. MODA: Mapping-Once Audio-driven Portrait Animation with Dual Attentions[J/OL]. 2023 IEEE/CVF International Conference on Computer Vision (ICCV) : 22963 – 22972, 2023. https://api.semanticscholar.org/CorpusID:259982892.
[20] Liu H, Zhu Z, Becherini G, Peng Y, Su M, Zhou Y, Zhe X, Iwamoto N, Zheng B, Black M J. EMAGE: Towards Unified Holistic Co-Speech Gesture Generation via Expressive Masked Audio Gesture Modeling[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024 : 11438 – 11448.
[21] 王耀南, 毛建旭. 智能机器人技术及应用研究现状与展望 [J]. 自动化学报, 49(6) : 1131 – 1153, 2023.
[22] NVIDIA Corporation. Audio2Face & Isaac Lab Documentation[Z]. 2023.
[23] Yi H, Zhou Y, others. Physical Intelligence through Simulation[J]. Nature Machine Intelligence, 2023.
[24] He T, Luo Z, He X, Xiao W, Zhang C, Zhang W, Kitani K, Liu C, Shi G. OmniH2O: Universal and Dexterous Human-to-Humanoid Whole-Body Teleoperation and Learning[C] // Conference on Robot Learning (CoRL). 2024.
[25] Luo Z, Cao J, Winkler A, Kitani K, Xu W. Perpetual Humanoid Control for Real-time Simulated Avatars[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2023.
[26] Fu Z, Zhao T Z, Finn C. Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024.
[27] Li C, Zeng R, Zhang T, Lu Y, Li K, Chi C, Xu Z, Song S. HumanPlus: Humanoid Shadowing and Imitation from Useful Real-World Data[J]. arXiv preprint arXiv:2406.10454, 2024.

（二）研究内容

（提纲不做限制，请按照研究工作的自身逻辑撰写。应提炼出特色与创新点、年度研究计划）

1.1 总体研究思路

本项目以**“面向共身智能的高表现力社交动作感知、映射与生成机制研究”**为核心命题，遵循**“多维感知解耦（数据解析层）→ 物理闭环映射（Sim-to-Real 桥梁层）→ 跨模态协同生成（认知-物理对齐层）”**的三层因果递进研究主线，针对轮盘式上半身人形机器人构型，建立从互联网人类社交视频出发、经物理约束桥梁、最终落地于真机高表现力交互的完整科学研究框架。本项目的总体研究内容与技术逻辑架构如图 2 所示。

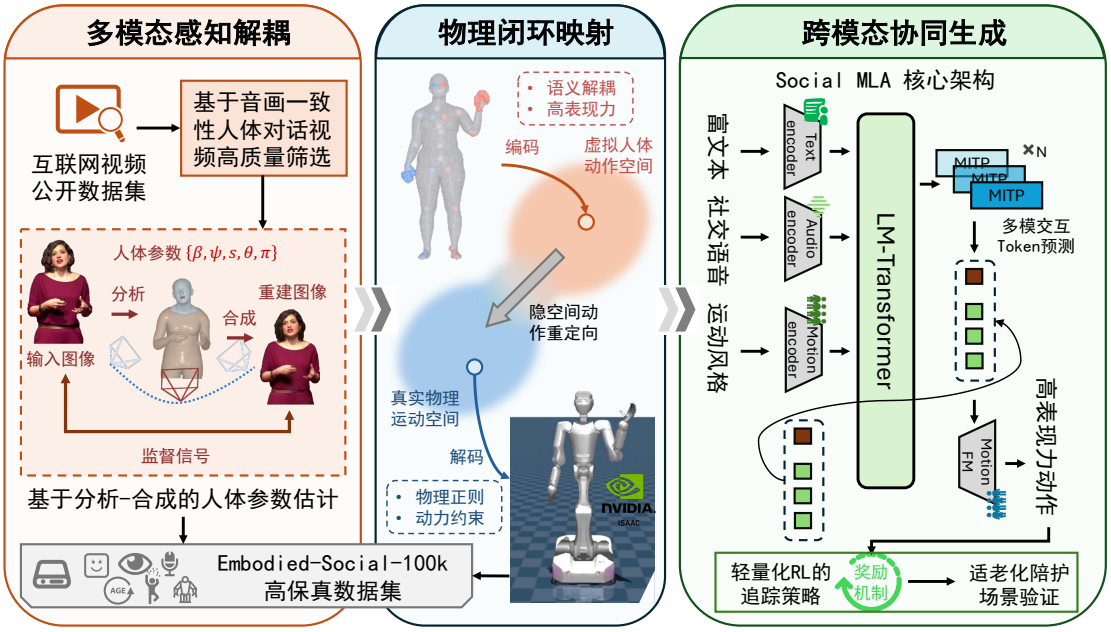

图 2. 本项目研究内容与技术架构图。展示了本项目三层因果递进研究逻辑：（左）以 Analysis-by-Synthesis 联合估计框架解析“表情-视线-动作”多维耦合特征，构建 **Embodied-Social-100k** 高保真数据集；（中）以 Isaac Lab 物理引擎反馈闭环驱动异构动作重定向，建立运动学-动力学联合约束的非线性拓扑映射；（右）以 **Social-MLA**（LM 离散语义规划 + Flow Matching 连续动作解码）实现跨模态动作流形的连续演化与对齐，最终在履带式人形机器人上实现高表现力社交交互。

第一层：数据解析层。以基于 Analysis-by-Synthesis 框架的联合估计机理为核心，攻克互联网视频数据和现有公开视频数据集中复杂交互遮挡下“表情-视线-动作”多维特征的时空同步解析难题；通过建立高精度的人体几何重建模型和高表现力人体参数模型，解耦情感判别性运动子空间与惯性运动子空间，为后续两层研究提供大量、多模态、语义感知先验。

第二层：Sim-to-Real桥梁层。以Isaac Lab物理仿真引擎的动力学反馈为内生约束，突破传统静态IK重定向的局限，建立运动学-动力学联合约束的非线性拓扑映射优化框架；通过动力学边界补偿机制处理拓扑异构所导致的奇异性，探究虚拟人体动作分布到真实运动分布的隐空间映射，构建兼具情感保真性与物理安全性的共生社交数据集（Enbodied Social 100K）。

第三层：认知-物理跨模态协同生成层。在上述数据基础上，以**Social-MLA**（LM离散语义规划 + Flow Matching (FM) 连续动作解码）为核心架构，探究情感语义离散表征对连续动作流形ODE演化的调制机理；以多部位时空耦合约束保障头-手-躯干协同生成的整体合理性；以轻量化RL追踪策略作为底层动力学安全辅助，最终在适老化陪护场景中验证Social-MLA的综合交互效能。

1.2 具体研究内容与实施方案

（1）研究内容一：复杂交互语境下的多模态感知解耦与参数化重构

正如本项目科学问题一所述，当前具身智能领域生成大模型（如VLA框架）面临的情感表现力缺失，其根源在于上游训练数据的贫瘠。传统的遥操作（Teleoperation）数据不包含面部与社会化手势，而现有的互联网动作捕捉技术（Motion Capture in-the-wild）往往孤立地处理人体的各个部位，缺乏对“表情-视线-动作”在复杂社交交互场景下的强时空耦合关联建模。

为此，本项目如图2左侧“多模态感知解耦”模块所示，拟建立从海量非结构化互联网视频与公开数据集中，逆向重构高精度虚拟人体动作空间（Virtual Human Motion Space）的全栈数据解析管线。本研究内容将重点突破基于音画一致性的高价值数据挖掘、遮挡环境下的多维特征时空同步解析，以及基于“分析-合成（Analysis-by-Synthesis）”的闭环参数化估计等关键技术，为下游的Sim-to-Real物理闭环映射提供语义解耦且高保真的参数化人体模型先验。本模块具体包含以下三个递进的研究线索：

研究线索1.1：基于音画一致性的高价值社交交互视频精细化筛选与多模态对齐机理。 高质量的具身生成基座模型严重依赖于规模化且语义严格对齐的数据支撑。尽管互联网中存在海量的对话、演讲、访谈等人类社交视频（如图2左上角所示的输入端），但此类公开原始数据普遍存在音画不同步、背景噪声干扰、多说话人重叠以及由于镜头频繁切换导致的动作时序割裂等“脏数据”问题。若直接将此类异构数据馈入3D位姿估计网络，将导致模型不可避免地学习到错误的“语义-动作”因果映射。因此，建立一套严密的、基于跨模态物理约束的高效过

滤与筛选机制，是构建 Embodied-Social-100k 数据集的先决条件。

本项目拟重点探究多模态信号在时域与频域空间中的强相关性判别模型。首先，针对视频帧序列 $\mathcal{V} \in \mathbb{R}^{T\times H\times W\times 3}$ 与对应的原始一维音频信号 $\mathcal{A} \in \mathbb{R}^{T'}$，引入具备高时序分辨率的主动说话人检测（Active Speaker Detection, ASD）与音画同步关联网络。具体实现上，采用双流特征编码架构：视觉流利用时空三维卷积（如 3D-ResNet）提取说话人面部（特别是唇部与下颌运动）的细粒度视觉动态特征序列 $\mathbf{f}_v \in \mathbb{R}^{T\times d}$；音频流则通过短时傅里叶变换（STFT）提取 Mel 频谱图，并经由 1D-CNN 编码为音频特征序列 $\mathbf{f}_a \in \mathbb{R}^{T\times d}$。为精确量化两者的同步状态，构建跨模态对比学习损失（Cross-modal Contrastive Loss），通过计算 $\mathbf{f}_v$ 与 $\mathbf{f}_a$ 之间的余弦相似度轨迹，提取音画同步置信度标量 $S_{sync}(t)$。结合心理声学模型中人耳对音画不同步的感知阈值（通常为视觉超前 45ms 或滞后 125ms，体现在 $S_{sync}(t) < 4$），设定自适应的软阈值边界，精确截取严格对齐的视频片段，从源头上剔除由后期配音或网络延迟造成的错位样本。

进一步地，针对具身智能交互场景对“非语言行为表达”的特殊需求，设计面向高表现力特征的片段价值挖掘算法。由于大量日常对话视频中人物躯干处于静止状态，缺乏丰富的伴随手势，此类低熵数据对训练模型的泛化能力贡献有限。本项目拟提出一种“运动表现力熵（Motion Expressivity Entropy）”的量化评价指标。通过轻量级 2D 人体关键点检测器提取画面中说话人的骨架关键点坐标序列 $\mathbf{K}_{2D}(t)$，计算其腕关节速度分布的方差、手部运动轨迹的凸包面积（Convex Hull Area）以及面部关键点（如眉毛、嘴角）的激活频次。综合多维度的运动学统计特征，赋予每个视频片段一个表现力得分 S_{expr}。最终，构建融合 S_{sync} 与 S_{expr} 的联合排序算法，实现对海量互联网视频的自动化、高质量、无人工干预的“沙里淘金”，确保输送至下一阶段的切片不仅语义对齐，且富含高频互动的社交动作模式。

研究线索 1.2：复杂交互与自遮挡条件下的多维特征时空同步解析架构。 在获取高质量视频切片后，提取其中的三维人体运动学参数是构建虚拟人体动作空间的核心。然而，真实的面对面社交交互不可避免地存在严重的肢体自遮挡（如手部托腮、双手交叉）以及人与环境/他人的互遮挡。传统的基于单帧图像直接回归的人体网格恢复算法，由于将头部、手部与躯干视作相互独立的感受野（Receptive Fields）进行处理，在遭遇局部遮挡时极易产生不可逆的姿态坍塌（Pose Collapse）或深度模糊（Depth Ambiguity）。另一方面，且上述方式依赖检测模型来预处理

提取人头，人手，人体等关键部位，带来额外的计算损失和误差累计。

为打破上述局限，本项目提出构建基于联合注意力机制的时空同步解析网络。该网络旨在挖掘人类非语言行为中“牵一发而动全身”的时空耦合先验（如：情绪高昂时，视线聚焦、眉毛上扬与手势的顶点在时间轴上往往呈现毫秒级的共现）。网络以前馈方式处理输入的RGB视频片段，提取全局与局部特征。在空域维度，摒弃传统将人体强行裁剪为多个独立Patch的割裂做法，引入具有全局感受野的视觉编码器(Vision Transformer, ViT)作为骨干网络。通过在网络深层设计显式的拓扑注意力掩码（Topology-aware Attention Mask），使得被严重遮挡的末端关节（如被身体遮挡的手掌）的特征重建，能够强依赖于其父节点（如手肘、肩膀）的运动状态以及面部表情的语义提示。在时域维度，引入带有因果掩码的时序维度注意力机制和时序卷积层（TCN），在潜变量空间（Latent Space）中通过建模相邻帧之间的运动学连续性，来补偿偿单帧中缺失的视觉观测信息。通过TCN强制执行低通滤波平滑约束，从而在隐空间层面实现高维特征矩阵的初步去噪与结构化解耦。

研究线索 1.3：基于“分析-合成（Analysis-by-Synthesis）”的闭环参数化重构与监督信号设计。 前馈神经网络虽能快速预测人体姿态的粗略分布，但在面部微表情、视线方向与手指精细动作等细粒度高频特征的拟合上依然存在不可忽视的误差。为获取足以支撑高表现力具身控制的“专家级”运动轨迹，本项目如图2左下方核心虚线框所示，提出建立基于“分析-合成（Analysis-by-Synthesis）”范式的可微闭环优化模型。

首先，统一参数化表达体系。拟采用SMPL-X与带有缩放的FALME来联合表示高表现力人体参数化模型（Expressive Human Model, EHM），其拓扑结构可由一组紧凑的参数集合 $\Phi = \{\beta, \psi, s, \theta, \pi\}$ 唯一确定。其中，$\beta \in \mathbb{R}^{400}$ 表征人体的身份与体型形状参数和人头形状参数（Shape）；$\psi \in \mathbb{R}^{100}$ 为人脸表情基系数（Expression），负责刻画微笑、蹙眉等瞬态情感特征；$\theta \in \mathbb{R}^{(J+2)\times 3}$ 囊括了包含脊柱、颈部与高自由度灵巧手指、眼球、下颚骨等在内的全身相对旋转姿态（Pose）；π 表征全局根节点的平移矩阵与弱透视相机的投影参数。

分析与合成过程的数学建模：在每一次优化迭代中，“合成（Synthesis）”阶段将当前网络预测的参数 $\hat{\Phi}$ 馈入可微的三维人体网格回归器。根据前向运动学（Forward Kinematics, FK）计算出 $N = 10475$ 个顶点的三维空间坐标 $\mathbf{V} \in \mathbb{R}^{N\times 3}$，并利用线性混合蒙皮（Linear Blend Skinning, LBS）算法处理网格变形。随后，通

过一个基于三维高斯溅射的可微渲染器（Differentiable Renderer）$\mathcal{R}(\cdot)$，将人体三维网格 $\mathbf{V}$ 和从参考图像 I_r 中提取的纹理特征进行融合并投影回二维像平面，生成重建的虚拟图像 $\mathcal{I}_{recon} = \mathcal{R}(\mathbf{V}(\hat{\Phi}), \hat{\pi}, I_r)$。

在此基础上，拟设计图像级别的光度一致性监督信号，构建驱动参数 $\hat{\Phi}$ 逼近真实物理运动流形的联合损失目标函数 $\mathcal{L}_{total}(\Phi)$。该目标函数由数据项与先验约束项复合而成：

$$\mathcal{L}_{total}(\Phi) = \lambda_{photo}\mathcal{L}_{photo} + \lambda_{kp}\mathcal{L}_{kp} + \lambda_{prior}\mathcal{L}_{prior} + \lambda_{temp}\mathcal{L}_{temp} \tag{1}$$

该目标函数包括以下子约束：1) **光度一致性约束 ($\mathcal{L}_{photo}$)**：直接计算输入原图 I 与重建图像 I_{recon} 在面部、手部以及整体的高频纹理区域的像素级L1范数差异。该项强迫模型提取像素级别对齐的人体三维网格，是提取微小情感语义特征和高精度人体自身和手部姿势的关键。2) **运动学投影误差 ($\mathcal{L}_{kp}$)**：计算三维关节坐标重投影后与现成2D关键点检测器提取的坐标（如DWPose）的加权鲁棒空间距离损失，确保整体骨架的空间位置不发生漂移。3) **混合高斯姿态先验 ($\mathcal{L}_{prior}$)**：由于从2D到3D的逆向映射属于典型的病态问题（Ill-posed Problem），存在多解性。本项目引入在大量数据集上预训练的VPoser变分自编码器构建姿态空间先验，对产生非自然人体骨架扭曲（如关节角度超出人体生理极限）的参数 $\hat{\theta}$ 施加指数级惩罚。4) **高阶时序平滑正则化 ($\mathcal{L}_{temp}$)**：为满足机器人底盘控制对指令平滑性的极高要求，在目标函数中对相邻帧的参数引入一阶速度与二阶加速度的二阶差分惩罚：$\mathcal{L}_{temp} = \sum_t \|\hat{\Phi}_t - 2\hat{\Phi}_{t-1} + \hat{\Phi}_{t-2}\|_2^2$。该设计从源头消除了高频抖动噪声，确保重构数据的物理可用性。

经过上述基于Analysis-by-Synthesis的交替下降与非线性优化求解，系统能够将二维视频像素空间中纠缠的光度、几何与时间信息，深度解耦为具有物理与语义双重属性的纯净三维人体参数序列。这批数据将作为极高质量的“虚拟人体动作分布”，无缝输送至本项目的第二层（中框）研究中，接受Isaac Lab物理引擎的动力学闭环映射与严苛筛选。

（2）研究内容二：受限物理实体约束下的隐空间闭环映射与数据集构筑

通过研究内容一的“分析-合成”管线，本项目已从海量互联网视频中解耦并提取出高精度的三维人体参数序列。然而，如图2中间的“物理闭环映射”模块所示，从“虚拟人体动作空间”到“真实物理运动空间”的跨越，面临着不可逾越的拓扑异构性与动力学鸿沟。高达145个自由度的柔性人体骨架与极度受限的刚性机器人（约20个自由度）之间，不仅存在一对多的病态映射关系，且由

于人体数据完全脱离了机器人自重、电机力矩极限与履带底盘的摩擦约束，直接应用传统运动学解算将导致严重的物理违例与动作语义折损。

为此，本模块旨在突破传统静态逆运动学（IK）的理论局限，探究融合语义先验的隐空间动作重定向机理，并将Isaac Lab物理引擎的动力学反馈作为内生约束引入优化闭环，最终构筑兼具高表现力与物理安全性的 Embodied-Social-100k 数据集。具体包含以下三个递进的研究线索：

研究线索 2.1：基于拓扑异构的隐空间动作重定向与语义解耦机理。 传统的重定向方法多在原始的三维关节欧氏空间（中通过最小化关节点距离（如MSE）来求解。这种生硬的几何映射会强制裁剪掉机器人无法复现的微小自由度，从而系统性地抹除诸如“轻微耸肩”、“手腕翻转”等承载高表现力的关键社交特征。本项目提出摒弃欧氏空间的直接映射，转而在高维流形的隐空间（Latent Space）中寻求跨实体的运动学对齐。

首先，构建面向虚拟人体动作空间与真实物理运动空间的非对称自编码器（Asymmetric Autoencoder）架构。定义源域为人体动作特征序列 $\mathbf{X}_H \in \mathbb{R}^{T\times D_H}$，目标域为机器人关节角度序列 $\mathbf{X}_R \in \mathbb{R}^{T\times D_R}$。设计深层时空图卷积网络（ST-GCN）作为编码器 $\mathcal{E}_H(\cdot)$，将异构的人体运动学链映射至一个共享的低维隐空间 $\mathcal{Z} \in \mathbb{R}^{T\times d_z}$，即 $\mathbf{z} = \mathcal{E}_H(\mathbf{X}_H)$。为实现图 2中所标示的“语义解耦”与“高表现力”保留，本项目在隐空间 $\mathcal{Z}$ 中引入对比学习（Contrastive Learning）与正交子空间投影机制。具体而言，将隐编码 $\mathbf{z}$ 显式解耦为情感语义特征 $\mathbf{z}_{sem}$ 与结构姿态特征 $\mathbf{z}_{pose}$。通过构建社交动作原语词典（Social Action Primitives Dictionary），对具有相同社交意图（如“安抚”、“拒绝”）但姿态略有不同的运动序列施加正样本拉近约束，强制 $\mathbf{z}_{sem}$ 捕获独立于本体拓扑结构的纯粹情感动态特征。

随后，设计适配于目标机器人运动学树（Kinematic Tree）的解码器 $\mathcal{D}_R(\cdot)$。解码过程并非简单的全连接映射，而是采用自回归的Transformer结构，将解耦后的隐变量解码为机器人关节序列：$\hat{\mathbf{X}}_R = \mathcal{D}_R(\mathbf{z}_{sem}, \mathbf{z}_{pose})$。在此阶段，定义运动学重定向损失函数 $\mathcal{L}_{retarget}$：

$$\mathcal{L}_{retarget} = \alpha_1 \|\mathbf{X}_H^{EE} - \mathcal{F}_{fk}(\hat{\mathbf{X}}_R)^{EE}\|_2^2 + \alpha_2 \mathcal{L}_{velocity} + \alpha_3 \mathcal{L}_{self-collision} \tag{2}$$

其中，第一项约束了源实体与目标实体在关键末端效应器（End-effector，如手掌心、头部朝向）在标准化空间中的相对轨迹一致性（即空间保真度）；$\mathcal{F}_{fk}(\cdot)$ 为机器人前向运动学求解函数；$\mathcal{L}_{velocity}$ 确保动作节律（如挥手的频率）的严格同

步；$\mathcal{L}_{self-collision}$ 则是基于距离场（SDF）的自碰撞惩罚项，用于避免双臂在胸前交叉或其他姿态运动时发生物理干涉。

研究线索 2.2：基于Isaac Lab物理引擎的闭环映射与动力学正则化机制。 仅依赖隐空间的运动学映射，虽然能够保证动作的语义高保真度，但在物理世界中往往是极其危险且不可执行的。例如，人体在激烈演讲时重心的快速偏移，若直接映射至履带式人形机器人，极易超出其零力矩点（ZMP）的稳定多边形，导致倾覆。因此，必须将“物理闭环（Physical Closed-loop）”引入映射过程。

本项目如图2中框的下半部分所示，得益于Isaac Lab的底层计算框架NVIDIA Warp以及最新集成的可微物理引擎Newton，本项目拟将高保真的物理仿真引擎封装为一个可微分的的物理层 $\mathcal{P}_{sim}(\cdot)$。将解码器输出的运动学轨迹 $\hat{\mathbf{X}}_R$ 作为参考轨迹，输入至Isaac Lab中进行正向动力学仿真。在仿真环境中，机器人不仅受到刚体动力学（Rigid Body Dynamics）的约束，还受到履带与地面摩擦力、关节伺服电机峰值力矩以及重力加速度的综合作用。仿真引擎将输出执行该轨迹时的真实物理状态序列 $\mathbf{S}_{sim} = \{\mathbf{q}, \dot{\mathbf{q}}, \tau, \mathbf{c}_{com}\}$（分别代表关节位置、速度、控制力矩及全局质心坐标）。基于此反馈，本项目构建严苛的“物理正则化”与“动力约束”惩罚函数 $\mathcal{L}_{physics}$：

$$\mathcal{L}_{physics} = \lambda_\tau \sum_t \max(0, \|\tau_t\| - \tau_{max}) + \lambda_{com} \sum_t \mathcal{D}(\mathbf{c}_{com}(t), \mathcal{P}_{support}) + \lambda_{jerk} \sum_t \|\dddot{\mathbf{q}}_t\|_2^2 \tag{3}$$

上式中，第一项为电机力矩超限惩罚，强制剥离那些导致关节过载的高频剧烈动作；第二项为质心偏移惩罚，$\mathcal{D}(\cdot)$ 计算实时质心 $\mathbf{c}_{com}$ 到履带底盘支撑多边形 $\mathcal{P}_{support}$ 边界的距离，确保在大幅度社交动作中底盘的绝对平衡；第三项为加加速度（Jerk）惩罚，保证动作的平滑度以延长机械臂寿命。

关键的创新点在于：本项目将上述物理正则项 $\mathcal{L}_{physics}$ 作为梯度反馈信号，反向传播至隐空间的解码器 $\mathcal{D}_R(\cdot)$ 与编码器 $\mathcal{E}_H(\cdot)$ 中。通过“隐空间运动学重构”与“物理引擎动力学校验”的端到端联合优化，解码器网络能够自动学会一种动力学边界补偿机制，即当某一人体社交动作（如深度鞠躬）在机器人上不可行时，网络不再生硬地截断动作，而是学会在隐空间中通过微调其他代偿关节（如微屈手臂、后移底盘）来维持相同的“社交语义特征”，从而实现表现力与安全性的联合最优解。

研究线索 2.3：高保真 Embodied-Social-100k 数据集的并行化构筑。 基于上述运动学-动力学联合约束的非线性拓扑映射框架，本项目将启动大规模数据的自动化清洗与构筑流水线。利用 Isaac Lab 强大的 GPU 并行张量加速能力，在仿真空间中同时实例化数千个带有不同社交动作参考轨迹的机器人环境（Envs）。

针对筛选后的人类互联网交互视频，批量系统性地执行“感知解耦 → 隐空间映射 → 物理引擎闭环校验 → 动态重优化”的完整流转。只有那些在 Isaac Lab 中能够稳定执行、未触发任何碰撞阈值、且电机能耗收敛于正常区间内的轨迹序列，才会被系统最终验收。验收通过的数据将被打包整合，正式定型为图 2左下方标注的 **Embodied-Social-100k 高保真数据集**。该数据集将首次在国际上提供包含“富文本指令-人类社交音频-隐空间动作 Token-物理安全的机器人 URDF 运动轨迹-底层力矩曲线”的多模态严格对齐样本。这一独有的数据资产，将填补了图形学虚拟生成与机器人底层控制之间的数据鸿沟，为后续第三层（右框）跨模态协同生成大模型（Social MLA）的训练，提供了不可或缺、且兼具“情感高表现力”与“真机直接可部署性”的重要数据支撑。

（3）研究内容三：Social MLA 核心架构驱动的跨模态协同生成与虚实迁移

依托前述研究内容构筑的 Embodied-Social-100k 高保真物理数据集，本项目从数据层面打通从多模态感知到物理安全运动状态的底层映射流转。然而，如图 2 右侧“跨模态协同生成”模块所示，面对未知的社交场景指令，如何使得机器人实时、自发地生成兼具情感表现力与动力学平滑性的连续交互动作，仍面临着“离散语义表征”与“连续物理流形”跨模态对齐的理论鸿沟。

为此，本项目提出并构建面向共身智能的 **Social MLA（Social Multi-modal Language-Model based Action generation）核心架构**。该架构突破了传统端到端回归模型的时序模糊性局限，创新性地采用“语言模型（LM）离散语义规划 + 流匹配（Flow Matching）连续动作解码”的级联演化范式。本模块将重点探究多模态 Token 的交互预测机理、连续具身动作流形的常微分方程求解（ODE）的演化规律，以及基于强化学习的底盘平衡控制，最终实现高表现力动作在真实物理世界的高保真部署。具体包含以下三个递进的研究线索：

研究线索 3.1：离散语义驱动的多模态交互 Token 预测（MITP）与 DiT/LM 特征融合机理。 高表现力的社交交互行为（如：伴随惊讶语气的后仰与手势停顿）在本质上具有高度的“组合性”与语义结构化特征。传统的扩散模型（Diffusion Models）往往在连续像素或运动学空间直接加噪去噪，难以显式地建模高层的情

感逻辑关联。因此，Social MLA 架构的首要任务是在高维隐空间中构建多模态语义的对齐与离散化表征机制。

如图 2右侧上半部所示，首先构建异构多通道编码器。针对输入的**富文本（Text）**指令集 $\mathcal{T}$，采用预训练的语言模型（如 SigLIP）提取深层意图特征 $\mathbf{h}_{text}$；针对输入的**社交语音（Audio）**片段 $\mathcal{A}$，引入 Wav2Vec 2.0 架构提取蕴含情感与节奏的声学副语言特征 $\mathbf{h}_{audio}$；同时，针对特定的**运动风格（Motion Style）**条件提示 $\mathcal{S}$，设计风格特征编码器提取风格潜向量 $\mathbf{h}_{style}$。为解决跨模态特征在时空维度的异构性，本项目引入基于 **Language Model Transformer（LM-Transofrmer）**）的混合骨干网络。将上述多模态特征投影至统一维度的隐空间，并通过多头交叉注意力机制（Cross-Attention）实现声学韵律与文本语义在时间步上的精准对齐。

在此基础上，提出**多模交互 Token 预测（Multi-modal Interactive Token Prediction, MITP）**机制。我们将连续的具身动作序列通过预训练的神经离散表示向量量化器（如 VQ-VAE 的 Codebook）离散化为有限的“社交动作词表（Social Action Vocabulary）”。利用大语言模型（LM）强大的自回归（Auto-regressive）上下文推断能力，将多模态融合特征作为前缀提示（Prompt），在时间轴上自回归地预测出长度为 N 的离散语义 Token 序列 $\hat{Z} = \{z_1, z_2, \ldots, z_N\}$。具体而言，在多模态交互 Token 的生成过程中，编码器前驱模块输出的隐状态 $\{z_{t-1}, \ldots, z_1, h_{t-1}\}$ 与多模态特征序列被作为联合条件输入，以调制当前时间步的 Token 分布。针对时间步 t 的离散交互 Token z_t，其自回归生成的条件概率可形式化为：

$$p_t(z_{t-1}, \ldots, z_1) \equiv \widetilde{P}\left[z_t \mid z_{t-1}, \ldots, z_1, h_{t-1}, \mathbf{c}_{t-1}, \ldots, \mathbf{c}_1\right] \tag{4}$$

其中，$z_{t-1}, \ldots, z_1$ 为历史已生成的社交动作 Token 序列；h_{t-1} 表示 LM-Transformer 混合骨干网络在上一时刻递推更新的高维隐状态；而 $\mathbf{c}_i \in \mathbb{R}^d$ 则代表在时刻 i 经由交叉注意力机制严格对齐后的多模态联合条件特征（即融合了前置模块输出的 $\mathbf{h}_{text}, \mathbf{h}_{audio}, \mathbf{h}_{style}$ 序列）。

通过在自回归解码路径中引入这种渐进更新的上下文条件信息流，MITP 机制能够有效抑制长序列预测中的误差累积。这一数理机制从根本上确保了语言模型（LM）在规划诸如“点头”、“摊手”等社交动作原语时，不仅严格遵循局部的动作连贯性，更受控于全局的情感逻辑约束与多模态时序因果关联，从而为后续的连续运动解码提供了结构极其严密的“离散语义骨架”。

研究线索 3.2：基于流匹配（Flow Matching）的连续具身动作流形解码与演化机理。 尽管MITP机制成功输出了富含情感逻辑的离散Token序列 $\hat{Z}$，但物理机器人的底盘电机与双臂关节执行器需要的是具备二阶连续可导属性的连续运动信号（即位置、速度指令）。若直接对离散Token进行最近邻解码插值，将引发严重的关节高频抖动（Jittering），进而损坏减速器或诱发底盘共振。

针对这一跨模态鸿沟，本项目如图 2右侧核心流线所示，创新性地引入**流匹配（Motion Flow Matching, FM）**作为连续高表现力运动解码器。相比于传统扩散模型中离散时间步的马尔可夫链加噪，流匹配通过构建连续时间的常微分方程（ODE），直接在目标运动数据分布与先验噪声分布之间构造最优传输（Optimal Transport）的确定性向量场，具有更优的轨迹平滑性与极高的采样效率。具体而言，设真实的连续机器人运动轨迹数据服从分布 $q(\mathbf{x})$，定义一个从标准正态分布 $p_0(\mathbf{x}) = \mathcal{N}(0, I)$ 到目标数据分布 $p_1(\mathbf{x}) \approx q(\mathbf{x})$ 的连续概率密度路径 $p_t(\mathbf{x})$（其中时间标量 $t \in [0, 1]$）。流匹配的核心在于学习一个由神经网络参数化的时变向量场 $v_\theta(\mathbf{x}_t, t, c)$，使其逼近边缘向量场 $u_t(\mathbf{x}_t)$。本项目将一个轻量的DiT作为底层架构对 v_θ 进行参数化，并引入由线索 3.1 输出的离散交互Token $\hat{Z}$ 以及音频融合特征作 $\mathbf{c}$ 为强条件引导。目标损失函数 $\mathcal{L}_{FM}$ 形式化为：

$$\mathcal{L}_{FM}(\theta) = \mathbb{E}_{t\sim\mathcal{U}[0,1],\mathbf{x}_1\sim q,\mathbf{x}_0\sim p_0}\left[\left\|v_\theta(\mathbf{x}_t, t, \hat{Z}, \mathbf{c}) - (\mathbf{x}_1 - \mathbf{x}_0)\right\|_2^2\right] \tag{5}$$

推理时，模型只需从高斯白噪声 $\mathbf{x}_0$ 出发，在离散语义Token $\hat{Z}$ 的条件引导下，使用如Euler法等数值积分器求解常微分方程 $d\mathbf{x}_t = v_\theta(\mathbf{x}_t, t, \hat{Z}, \mathbf{c})dt$，积分至 $t = 1$ 即可确定性地生成连续的运动信息。这一机制上揭示了**跨模态协同生成的理论本质**：即以离散的社交意图Token $\hat{Z}$ 调制常微分方程的非线性漂移项，迫使生成的机器人的连续物理运动流形严格沿着人类社交情感的概率边界演化，打破了流匹配模型“平滑却无逻辑”与自回归模型“有逻辑却不连续”的工程僵局。

研究线索 3.3：融合底盘平衡与动力学约束的强化学习追踪策略与虚实迁移真机验证。 依托Social MLA架构，系统已能输出兼具情感语义与时序平滑性的参考轨迹和运动信息。然而，真实的履带式人形机器人在执行高表现力交互动作时，上半身（的大幅挥动与瞬态前倾会产生极大的动态扰动力矩。若仅依赖底层电机的传统位置伺服（PD Control），极易引发履带底盘的打滑、抬起甚至整体倾覆。

为此，如图 2右下角所示，本项目提出构建**基于强化学习（RL）的鲁棒追踪策略**，完成从仿真空间向真实物理世界的“最后一公里”闭环迁移（Sim-to-Real

Deployment）。在 Isaac Lab 仿真环境中，将底盘与上半身作为一个耦合的多刚体动力学系统进行建模。定义 RL 策略网络 $\pi_\phi(\mathbf{a}_t|\mathbf{s}_t)$，其状态空间 $\mathbf{s}_t$ 不仅包含机器人的本体感知数据（关节角度、角速度、IMU 测量的底盘俯仰/横滚角），还通过观测历史窗口融合了由 Social MLA 生成的未来参考轨迹帧 $\mathbf{x}_{ref}(t:t+H)$。运动信息空间 $\mathbf{a}_t$ 输出为各伺服电机的目标位移或前馈力矩指令。针对高动态社交交互对底盘稳定性的严苛要求，本项目设计深度耦合的复合奖励函数 $\mathcal{R}_t$：

$$\mathcal{R}_t = \omega_{trk}\exp(-\|\mathbf{q}_t - \mathbf{q}_t^{ref}\|_2^2) + \omega_{bal}\exp(-\|\dot{\mathbf{r}}_{chassis}\|_2^2) - \omega_\tau\|\tau_t\|_2^2 - \omega_{cmd}\|\mathbf{a}_t - \mathbf{a}_{t-1}\|_2^2 \tag{6}$$

其中，第一项驱动机器人对 Social MLA 输出的高表现力动作进行高精度几何追踪；第二项 ω_{bal} 为关键的**底盘平衡约束**，严厉惩罚履带底盘在俯仰（Pitch）与横滚（Roll）方向的非预期角速度 $\dot{\mathbf{r}}_{chassis}$，迫使策略网络学会在上半身剧烈运动时，通过微调履带电机的差速补偿来抵消质心偏移；后两项则限制了能量消耗与控制指令的高频突变（Jerk），实现**功耗均衡**与动作柔顺。

最终，通过域随机化（包括扰乱质量分布、履带摩擦系数与电机响应延迟）提升 RL 策略的鲁棒性。将训练收敛的追踪策略零样本（Zero-shot）部署至真实的履带式人形机器人上。在面向适老化陪护、自然语音问答等典型人机共融场景中，系统性验证机器人在物理世界中执行诸如“附和点头”、“摊手安慰”、“激动演讲”等高表现力动作的自然度、安全性与底盘抗扰动能力，全面验证 Social MLA 核心架构的科学合理性与落地可行性。

1.3 特色与创新之处

本项目立足于国家“人工智能+”与银发经济战略，针对具身智能在非语言交互能力上的严重缺失，跳出传统“以物理作业为核心”的研究窠臼。本研究在理论视角、映射机制与生成架构等维度较现有方法实现了系统性跃升，其核心方法创新对比总览如表 1 所示，本项目的具体特色与创新之处凝练为以下三点：

（1）视角与感知机制创新：从“物理具身”向“认知共身”跃升，提出基于 Analysis-by-Synthesis 的多维非语言特征解耦理论。 现有具身大模型多聚焦于末端执行器的物理操作，严重忽略了人机交互中的副语言与情感维度。本项目的核心特色在于率先引入“共身智能（Cobodied AI）”前沿理念，将研究目标提升至“跨智能体认知与物理双重对齐”。**理论突破：**突破了传统计算机视觉中将面部、视线与动作作为独立分支进行前馈估计的局限，创新性地提出基于“分析-合成”

表 1: **本项目核心研究方法与现有主流范式的创新对比**

比较维度	**现有主流方法（传统VLA/数字人）**	**本研究创新（Social-MLA框架）**
核心理论视角	物理环境适应（侧重目标导向的操作）	**跨智能的认知对齐**（共身智能理念驱动）
多模态感知解析	各部位割裂的单向估计（易受遮挡失效）	基于 **Analysis-by-Synthesis** 的时空同步联合解耦
虚实映射机制	静态纯运动学求解（无物理反馈的IK）	**物理闭环的动力学补偿**（隐空间非线性映射）
动作生成范式	单一空间的端到端回归 / 纯扩散生成	**自回归离散语义规划 + 连续流匹配（ODE）演化**
底层控制与部署	刚性位置伺服（遇高动态社交动作易失稳）	**融合底盘平衡的强化学习追踪**（动态抗扰动）

范式的闭环时空解析模型。通过在参数空间引入光度一致性与高阶时序平滑等物理正则项，首次实现了复杂交互遮挡下“表情-视线-动作”多维耦合特征的时空同步解耦，为具身智能提供了兼具高表现力与物理真实性的语义感知先验。

（2）物理映射理论创新：打破静态运动学映射局限，建立受物理引擎内生约束的隐空间非线性拓扑映射与动力学补偿理论。 将高达百余个自由度的柔性人体动作重定向至受限的刚性机器人时，拓扑异构与动力学极限导致传统逆运动学（IK）面临严重的语义折损与物理违例。本项目的特色在于从底层数学机理上打通了图形学数字人与机器人底层控制的“虚实鸿沟”。**理论突破：**创新性地将高保真物理仿真引擎（Isaac Lab）的刚体碰撞与动力学反馈（如电机力矩超限、质心偏移边界）封装为梯度反馈信号，反向注入隐空间（Latent Space）的动作编解码闭环中。该理论实现了从“事后物理裁剪”向“事前动力学边界补偿”的根本性转变，使得网络能够自动在约束流形上寻求“社交语义关键帧保真度”与“机器人动力学可行域”的联合最优解。

（3）跨模态生成范式创新：提出Social-MLA架构，揭示离散语义Token对连续具身动作流形ODE演化的跨模态调制规律。 高表现力交互动作同时具备高层情感的离散逻辑性与底层物理控制的连续平滑性，这是单一自回归语言模型（LM）或连续生成模型难以逾越的模态鸿沟。本项目的核心特色在于提出融合两者的级联生成架构。**理论突破：**首次建立了“离散语义规划+连续动作解码”的级联数学表达。在多模交互Token预测（MITP）中引入渐进更新的上下文条件信息流，通过级联自回归机制严格约束动作的宏观社交逻辑；更重要的是，探明了该离

散多模态交互序列如何作为强条件引导变量，有效调制流匹配（Flow Matching）常微分方程（ODE）的非线性漂移项。该机理保障了生成的连续物理运动流形严格沿着人类社交情感的概率边界演化，解决了具身动作生成中“逻辑时序性与物理平滑性不可兼得”的科学难题。

1.4 年度研究计划及预期研究结果

（1）年度研究计划（2027.01 —— 2029.12）

本项目研究周期为三年，严格遵循“多维感知解耦 → 核心架构研发 → 物理迁移部署”的层级递进科学逻辑。表 2 展示了本项目每年的阶段划分、研究重点、核心任务与预期产出。具体而言，各年度的实施方案与执行细节安排如下：

表 2: **本项目三年期研究计划与预期成果汇总表**

研究阶段	研究重点	核心任务	预期成果
第一年度 (2027 年)	多模态感知解耦与物理闭环映射	基于 Analysis-by-Synthesis 的时空同步解析；构建融合 Isaac Lab 动力学反馈的隐空间重定向机制	构筑并开源 Embodied-Social-100k 数据集；论文 1 篇，专利 1 项
第二年度 (2028 年)	Social-MLA 核心架构研发与生成演化	研发多模交互 Token 预测（MITP）模块；揭示离散语义对常微分方程（ODE）连续演化轨迹的调制机理	确立 Social-MLA 算法原型；论文 1 篇、专利 1 项
第三年度 (2029 年)	虚实迁移控制策略与实景验证部署	设计融合底盘平衡的 RL 抗扰动追踪策略；在履带式人形机器人上开展高表现力交互的主客观综合测评	完整软硬件验证系统；论文 1 篇、专利 1 项

第一年度（2027.01 — 2027.12）：复杂交互感知解耦与物理闭环数据集构筑 本年度聚焦于打通数据壁垒，为生成大模型提供高质量的感知先验与数据基座。

- **机理探究与算法研发：**重点研发基于音画一致性的高价值交互数据自动化筛选管线；构建基于 Analysis-by-Synthesis 范式的闭环时空解析网络，突破遮挡环境下“表情-视线-动作”的联合解耦与高保真参数化重构难题。
- **仿真搭建与动力学校验：**搭建目标履带式人形机器人的 Isaac Lab 高保真物理仿真环境并精确标定动力学参数；探究隐空间动作重定向网络，将物理引擎的力矩与质心偏移惩罚作为梯度反馈注入网络，完成动力学边界补偿机制的训练。
- **阶段性测试：**跑通“Video-to-Sim”自动化数据流转闭环，完成至少 10 万规模级的高表现力对齐样本生成，正式定型 Embodied-Social-100k 数据集。

第二年度（2028.01 — 2028.12）：Social-MLA 核心生成架构设计与跨模态对齐研究 本年度为本项目的核心攻坚期，全面开展基于大模型与流匹配的跨模态协同生成机制研究。

- **架构搭建与级联自回归设计：**设计异构多模态特征编码器与融合模块；研发多模交互Token预测（MITP）机制，利用大语言模型完成离散语义的自回归时序规划，并在解码路径中引入渐进更新的上下文条件信息流。
- **连续流形演化与模型联调：**深度探究流匹配模型在具身动作生成中的数学表达，推导并实现离散语义Token对连续动作常微分方程（ODE）非线性漂移项的条件调制；利用第一年构筑的数据集对 Social-MLA 架构进行端到端联合训练。
- **阶段性测试：**建立离线评测基准，利用语义一致性分数、动作平滑度等客观指标，论证架构在跨模态对齐与时空协同生成上的优越性。

第三年度（2029.01 — 2029.12）：底层鲁棒控制策略研制与适老化真机场景落地 本年度重点攻克虚实鸿沟（Sim-to-Real），验证项目理论在真实物理世界中的系统效能。

- **追踪策略与抗扰动研究：**针对履带式机器人构型，研究基于强化学习（RL）的底层追踪控制策略；设计融合底盘稳定性约束（如俯仰/横滚角惩罚）与动作跟踪精度的复合奖励函数，探索域随机化技术以克服Sim-to-Real摩擦与延迟分布差异。
- **系统集成与实景验证：**将训练收敛的 Social-MLA 生成模型与 RL 追踪策略无缝部署至真实履带式双臂人形机器人硬件平台；在适老化陪护、自然语音问答等典型交互场景中，开展大规模的人机交互主观实验与底盘抗扰动压力测试。
- **项目结题与成果总结：**整理实验数据，撰写高水平学术论文与项目结题报告，推动相关数据集与核心算法的开源共享工作。

（2）预期研究结果

本项目预期在理论机理突破、核心算法研发、数据生态构建以及人才梯队培养等方面取得如下实质性成果：

（1）基础理论与核心算法：提出并完善一套面向共身智能的跨模态动作感知、映射与生成理论框架；从底层数学机理上揭示离散意图Token驱动连续具身动作ODE流形演化的跨模态调制规律；构建并定型Social-MLA高表现力动作生成算法原型。

（2）高保真数据集与开源生态：构筑并开源国际上首个兼顾动力学约束与多模态情感语义严格对齐的高保真具身社交数据集 **Embodied-Social-100k**；开源相关的“分析-合成”多维解析代码与物理闭环映射接口，填补学术界在高质量共身交互数据上的空白。

（3）知识产权与高水平学术论文：预期在 *IEEE TPAMI, IJCV, CVPR, ICCV, ICLR, ICRA* 等人工智能、计算机视觉与机器人领域内顶级国际期刊与会议上发表高质量学术论文 3-4 篇；针对Social-MLA核心生成架构与底盘平衡追踪策略，申请并获得授权国家发明专利 3-4 项。

（4）物理验证系统与人才梯队建设：形成一套软硬件协同的高表现力履带式机器人社会化交互验证系统；以本项目的实施为重要契机，培养 2-3 名精通图形学生成算法与机器人底层控制的交叉学科拔尖研究生，构筑具有强竞争力的青年科研创新团队。

（三）研究基础

1. 研究基础与可行性分析（与本项目相关的研究工作积累和已取得的研究工作成绩，研究风险的应对措施等）；

1.1 相关研究工作积累与已取得的成绩

申请人长期深耕于**3D计算机视觉、生成式人工智能与多模态人机交互**领域，在 *CVPR, ICCV, SIGGRAPH* 等顶级会议发表多篇高水平论文。申请人团队在“数字空间”构建的高保真感知与生成技术体系，不仅在算法层面为本项目的Social-MLA模型提供了核心模块（感知编码器与流匹配解码器），更在数据层面为解决具身智能“高表现力数据匮乏”难题奠定了坚实基础。

1. 高表现力3D面部与全身协同生成算法积累　针对机器人交互中“表情僵硬、肢体不协调”的痛点，申请人前期工作突破了多模态语义到高维动作空间的映射瓶颈。

- **面部驱动方面：**提出了神经辐射场（NeRF）与显式网格耦合的混合建模方法，实现了语音驱动的发丝级精度3D头部动画生成。研发了基于Trans-

former 的跨模态对齐网络，解决了长语音序列中的唇形同步与情感韵律（Prosody）解耦难题（相关成果发表于 **CVPR 20xx**）。这为驱动机器人的仿生面部或屏幕人脸提供了成熟的算法基座。

- **全身协同方面：**针对伴随语言的非语言行为生成，提出了基于扩散模型（Diffusion Model）与 VQ-VAE 的全身协同生成框架，实现了根据语音节奏（Beat）自动生成大幅度手势、躯干微动及头部姿态。同时，在人体姿态估计（SMPL-X Recovery）方面积累了鲁棒的野外视频捕捉算法。上述工作直接支撑了本项目**模块一（数据构建）**与**模块二（协同模型）**，使得利用互联网海量视频数据低成本训练机器人策略成为可能。

2. 实时多模态交互系统集成经验　申请人主导研发了“高保真实时交互数字人系统”，打通了 ASR（语音识别）、LLM（意图理解）、TTS（语音合成）与 Audio-to-Motion 的全栈链路，在消费级显卡上实现了毫秒级的端到端响应。该系统的架构逻辑与本项目 Social-MLA 的 LM+流匹配推理链路高度同构，申请人在并发调度、显存优化及端云协同方面的研究经验，能够有力保障算法在物理机器人计算平台上的实时性与鲁棒性。

3. 针对本项目的初步探索与预研进展　为了验证“共身智能”与“虚实迁移”技术路线的可行性，项目组依托合作单位的**履带式人形机器人**平台开展了实质性预研（如图 3 所示）：

（1）**异构重定向验证：**开发了基于优化控制的 Motion Retargeting 算法，成功将 SMPL-X 人体骨骼数据映射至机器人 URDF 关节空间，有效保留了挥手、点头等社交动作的语义关键帧。

（2）**Sim-to-Real 物理仿真：**基于 NVIDIA Isaac Lab 搭建了高保真仿真环境，导入了精确的机器人动力学参数。已跑通基于强化学习（RL）的追踪策略，初步验证了在电机力矩限制下复现高动态手势的可能性。

（3）**Social-MLA 基座模型：**利用高质量演讲视频数据，训练了 Social-MLA 基座模型，该模型已初步揭示情感标签对生成动作多样性的调制规律，具备根据情感语义生成差异化肢体语言的基础能力。

1.2 可行性分析

1. 理论可行性：共身智能范式的指引　本项目基于陆峰教授与赵沁平院士提出的“共身智能”前沿理论，将成熟的图形学生成技术与机器人学控制理论相结合。

此处插入：图 3 项目组前期预研验证结果
（绘图建议：(a) 从视频提取的高精度 SMPL-X 数据；(b) 映射至履带式机器人的运动学解算结果；(c) Isaac Lab 物理仿真中的动作追踪与平衡控制验证）

图 3. 项目组前期预研验证结果。展示了从单目视频提取 SMPL-X 人体数据，经由异构重定向算法映射至机器人关节空间，并最终在 Isaac Lab 物理仿真环境中完成动力学验证的完整流程，证明了 "Video-to-Sim-to-Real" 技术路线的可行性。

"Video-to-Sim-to-Real" 的数据闭环范式已在 HumanPlus、Mobile ALOHA 等近期顶会工作中得到验证，理论路径清晰，科学依据充分。

2. 技术可行性：全栈技术储备与仿真验证 申请人团队已掌握了从 3D 感知、动作生成到仿真控制的关键技术栈。Isaac Lab 等新一代物理仿真平台的出现，极大地降低了 Sim-to-Real 的迁移难度。前期的预研实验已打通了核心链路，证明了在仿真环境中进行动力学筛选与策略学习的有效性，技术风险可控。

3. 硬件与环境保障 依托（**填写研究院名称**）与（**填写合作公司名称**）的深度合作，本项目拥有**履带式双臂人形机器人**的完全开发权限及底层控制 SDK 支持，规避了 "有算法无硬件" 的落地难题。同时，团队拥有的高性能计算集群（A100/H100）为大模型训练与大规模并行仿真提供了充足的算力保障。

1.3 研究风险及应对措施

1. 风险：Sim-to-Real 迁移中的模型失配（Reality Gap） 描述：仿真环境中的摩擦系数、电机阻尼等参数难以与真实物理环境完全一致，可能导致生成的动作在真机上出现抖动或跟踪误差。**应对措施：** (1) **系统辨识与域随机化（Domain Randomization）：**在 Isaac Lab 训练阶段，对机器人的质量分布、关节摩擦、延迟时间等物理参数引入高斯噪声扰动，训练鲁棒性更强的策略网络；(2) **在线自适应控制：**在真机部署端引入基于本体感知（Proprioception）的适应性模块，根据实时的关节力矩反馈动态调整 PD 控制增益。

2. 风险：高动态交互下的底盘稳定性　描述：履带式机器人在进行大幅度上半身动作（如快速挥手、前倾）时，重心变化可能导致底盘晃动甚至倾覆。**应对措施：** (1) **全身动力学耦合规划：**在重定向算法中引入零力矩点（ZMP）约束，将底盘稳定性作为优化目标的一部分；(2) **分层安全策略：**设计底层的安全保护层（Safety Layer），实时监控IMU数据。一旦检测到倾角超限，立即接管上层生成指令，强制执行姿态恢复动作，确保物理安全。

3. 风险：多模态生成数据的语义一致性不足　描述：互联网视频数据存在噪声，可能导致生成的动作与语音情感不匹配（如悲伤语音对应大幅度动作）。**应对措施：** (1) **CLIP语义过滤：**构建基于CLIP的自动化清洗管线，计算视频帧与情感标签的语义相似度，剔除离群样本；(2) **人工与大模型混合校验：**在关键节点引入GPT-4V或人工抽检机制，确保Embodied-Social-100k数据集的高质量与对齐精度。

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、全国重点实验室和部门重点实验室等研究基地的计划与落实情况）；

2.1 已具备的实验条件

本项目依托申请人所在单位的高水平科研平台，在硬件设备、算力资源、数据积累及团队梯队等方面已具备了坚实的研究基础，能够完全保障项目的顺利实施。

1. 硬件平台与机器人实验环境　实验室与国内具身智能领军企业（**星辰智能**）建立了深度科研合作伙伴关系，已在实验室部署了**履带式双臂人形机器人**作为本项目的主力验证平台。该机器人配备高精度灵巧手、多自由度头颈模组及双目深度相机，开放了底层的关节力矩控制接口（SDK）与运动学解算库，完全满足Social-MLA模型从算法验证到真机部署的硬件需求。此外，实验室配备了**OptiTrack光学动作捕捉系统**与**Xsens惯性动捕设备**，能够实时采集高精度的真实人体社交动作数据，用于算法的基准真值（Ground Truth）对比与评估。

2. 高性能计算与仿真算力资源　申请人所在研究院计算中心已建成大规模高性能计算集群，配备**NVIDIA A100/H100 Tensor Core GPU**节点共计（**填写数**

量）个，存储容量达PB级，并部署了InfiniBand高速互联网络。该算力平台已预装NVIDIA Isaac Lab、Omniverse等物理仿真引擎及PyTorch深度学习框架，能够充分支撑Social-MLA大模型的分布式训练以及百万级并发的Sim-to-Real强化学习仿真任务。

3. 前期数据与算法代码库 项目组前期已积累了约（**200小时以上**）的高质量互联网演讲与交互视频数据，并完成了初步清洗与SMPL-X参数化处理，构建了**Embodied-Social-Pre**预训练数据集。同时，团队自主研发了包含Motion Retargeting、语音驱动表情生成及全身协同生成的全栈代码库，为本项目的快速启动奠定了软件基础。

2.2 利用国家/重点实验室等研究基地的计划与落实情况

本项目将紧密依托（**填写依托单位的国家重点实验室或部门重点实验室名称，例如：虚拟现实技术与系统全国重点实验室 / 机器人学国家重点实验室**）开展研究工作，计划落实情况如下：

1. 依托重点实验室的理论指导与学术交流 项目将纳入重点实验室的年度研究计划体系，接受（**填写院士/实验室主任姓名**）院士及学术委员会的定期指导。充分利用实验室在“人机共融”与“虚拟现实”领域的顶级学术网络，定期邀请国内外具身智能领域的专家进行研讨，确保项目技术路线始终处于国际前沿。

2. 共用重点实验室的特种实验设施 计划利用重点实验室的**大型沉浸式交互实验场**（**或填写具体的实验室设施名称**），开展人机共身交互的主观评测实验。该实验场具备可控的光照、声场环境及全方位生理信号监测设备（如脑电EEG、皮电EDA），为评估老年人在与机器人交互过程中的真实情绪反馈与认知负荷提供了科学的实验环境。

2.3 尚缺少的实验条件和拟解决的途径

尽管项目组已具备核心研发条件，但在**真实适老化场景的复杂性验证**及**极端工况下的数据完备性**方面仍存在一定缺口，拟通过以下途径解决：

1. 尚缺少：真实居家/养老机构的复杂交互场景 拟解决途径：依托合作企业（**公司名**）的行业渠道资源，计划在项目第三年度，与（**填写具体的养老院/社区名称，或写“北京市某主要养老示范社区”**）建立**“具身智能适老化应用示范点”

**。将实验从实验室的结构化环境延伸至真实的非结构化生活场景，在严格的安全监管下收集真实用户的交互反馈数据，以验证系统的鲁棒性与社会接受度。

2. 尚缺少：机器人极端工况下的本体感知数据　拟解决途径：真实机器人难以进行破坏性实验（如剧烈碰撞、跌倒），导致极限边界数据缺失。项目组将充分利用**Sim-to-Real技术**，在Isaac Lab仿真环境中构建高保真的“数字孪生”场景，通过程序化生成（Procedural Generation）技术合成大规模的极端交互数据（如拥挤人群、复杂障碍物），通过**合成数据增强（Synthetic Data Augmentation）**的方式填补真实数据的空白，提升策略网络的泛化边界。

3. 正在承担的与本项目相关的科研项目情况（申请人正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等）；

无。

4. 完成国家自然科学基金项目情况（对申请人负责的前一个已资助期满的科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要（限500字）和相关成果详细目录）。

无。

（四）其他需要说明的情况

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系；已收到自然科学基金委不予受理或不予资助决定的，无需列出）。

无。

2. 具有高级专业技术职务（职称）的申请人是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

无。

3. 具有高级专业技术职务（职称）的申请人是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

无。

4. 同年以不同专业技术职务（职称）申请或参与申请科学基金项目的情况（应详细说明原因）。

无。

5. 其他。

无。